

AI 품질 예측 분석

사출성형 불량 예측 모델 개발 프로세스 · STEP 1 - 4



데이터셋 KAMP(한국형 제조 AI 데이터셋) · 현대자동차 아반떼 CN7 · 앞유리 사이드 몰딩 사출성형 공정 데이터



github.com/s01022087242-cloud/CN7-

팀 역할 분담

데이터 파이프라인부터 응용(추천 시스템)까지, 3인이 파트를 나누어 협업



김재원



데이터 전처리



검증 개선



응용 추천 시스템



오선규



데이터 학습 분석



검증 개선



응용 추천 시스템



성재원



데이터 수집



검증 개선



응용 추천 시스템

사용한 프로그램 및 라이브러리

PyCharm 기반 Python 개발 환경 · 데이터 처리부터 모델 학습·UI 구현까지



개발 환경 PyCharm — Python 통합 개발 환경(IDE)에서 데이터 분석부터 모델 학습, UI 개발까지 진행

사용 라이브러리



pandas

CSV 파일과 표 데이터를 처리합니다.



NumPy

숫자와 배열 계산에 사용합니다.



scikit-learn

모델 예측과 성능 평가에 사용합니다.



joblib

저장된 PKL 모델을 불러옵니다.



Matplotlib

기본 그래프를 그립니다.



Seaborn

히트맵과 통계 그래프를 그립니다.



Tkinter

프로그램 화면(UI)을 만듭니다.



os

파일명과 시스템 경로를 처리합니다.



pathlib

모델 파일 경로를 관리합니다.

시스템 아키텍처 — 불량 예측 프로그램 구조

Tkinter UI부터 사전 학습 모델 로드, 예측 성능 확인까지 전체 프로그램 구조



전체 분석 파이프라인 흐름도

데이터 준비 → 모델 선정 → 전처리·학습 → 실전 평가까지, 4단계 엔드투엔드 프로세스



데이터셋 소개

KAMP 사출성형 공정 데이터 · 현대자동차 아반떼 CN7 앞유리 사이드 몰딩



💡 처음에는 원본 데이터로 모델을 학습했지만, 불량 표본이 너무 적어 SMOTE 기법으로 불량 데이터를 증강한 두 번째 데이터셋 제작

① 원본 데이터

real_data.csv

KAMP CN7 앞유리 사이드 몰딩 원본 로그(전처리 전, RH·LH 기준)

6,736건

CN7 데이터 건수

45개

전체 컬럼 (원본 그대로)

0.6%

불량률 (양품 6,697 · 불량 39)

주의 · 불량 표본이 지나치게 적어 모델이 불량 패턴을 충분히 학습하기 어려움



SMOTE로 불량 표본 증강

② 증강 데이터 (SMOTE)

add_data.csv

①의 불량 표본을 SMOTE로 늘려 만든 학습용 증강 데이터(전처리 완료)

15,850건

증강 후 데이터 건수

30개

컬럼 (스케일링·원-핫 인코딩)

50:50

균형 (양품 7,925 · 불량 7,925)

활용 · 원본 데이터로 데이터 분석, 증강 데이터로 UI용 모델 학습

※ 두 데이터셋 모두 시간·위치·속도·압력·온도 등 동일한 사출성형 공정 센서값을 담고 있으며, 증강 데이터는 수치형 변수 표준화와 설비명 원-핫 인코딩까지 마쳐 학습에 바로 사용할 수 있는 형태

1

STEP 1

데이터 준비 및 분할

원본 데이터를 정제하고, 학습·평가용으로 미리 나눠 둔다



1-1 원본 데이터(df) 로드

수집된 사출성형 공정 데이터셋을 데이터프레임으로 불러오기



1-2 무의미한 컬럼 제거

전부 0인 값, ID 등 학습에 기여하지 않는 컬럼 정리



1-3 타겟 변수 변환

Pass / Fail 라벨을 1 / 0 으로 이진 인코딩



1-4 Train / Test Split

전체 데이터를 8 : 2 비율로 분할

Train / Test Split (8 : 2)

Train 80%

Test
20%



Train Data (80%)

STEP 2 최적 모델 선정으로 이동

베이스라인 모델 비교 → 전처리·정밀 학습으로 순차 투입



Test Data (20%)

STEP 4 최종 평가 전까지 봉인

학습 과정에 절대 노출되지 않음 → Data Leakage 방지

데이터 전처리 — 제거한 컬럼

원본 데이터(전처리 전, real_data.csv) 기준 · 44개 후보 컬럼 중 17개 제거



44개

전체 후보 컬럼 (종속변수 제외)



17개

제거한 컬럼



27개

최종 독립변수

관리용 · 불필요 컬럼

7개



_id

데이터 식별번호



TimeStamp

데이터 기록 시간



PART_FACT_PLAN_DATE

생산 계획 날짜



PART_FACT_SERIAL

생산 일련번호



PART_NAME

부품 이름



EQUIP_CD

설비 코드



Reason

불량 발생 후 작성되는 불량 사유

값이 일정한 금형 온도 컬럼

10개



Mold_Temperature_1



Mold_Temperature_2



Mold_Temperature_5



Mold_Temperature_6



Mold_Temperature_7



Mold_Temperature_8



Mold_Temperature_9



Mold_Temperature_10



Mold_Temperature_11



Mold_Temperature_12



고유값이 1개 이하인 상수 열이라 예측에 도움이 되지 않아 제외됩니다.

데이터 전처리 — 분석하는 독립변수

17개 제거 후 확정된 27개 독립변수 · EQUIP_NAME 원-핫 인코딩 시 최종 모델 입력 29개



공정 시간 · 위치

9개

사출·충전·가소화시간·사이클타임·형체결시간, 쿠션·전환·가소화·형개 위치



속도 · 회전수

3개

최대사출속도, 스크류 RPM(최대·평균)



압력

4개

최대사출압력·최대전환압력·배압(최대·평균)



배럴 · 호퍼 온도

8개

배럴온도 7구간 · 호퍼온도



금형 온도

2개

Mold_Temperature_3 · Mold_Temperature_4 (값이 변하는 구간만)



설비 정보

1개

EQUIP_NAME → 원-핫 인코딩 시 3개 컬럼으로 확장




종속변수 1개 PassOrFail — Y → 양품(0) · N → 불량(1)

탐색적 데이터 분석(EDA) — 불량 현황과 원인




원본 데이터(real_data.csv) 기준 · Pass/Fail 분포 및 불량 사유 분석

Pass / Fail Count



Distribution of Failure Reasons




전체 데이터 기준 불량 71건은 가스(35건) · 초기허용불량(20건) · 미성형(16건) 3가지 사유로 전량 분류됨 — 극심한 클래스 불균형(약 0.9%)을 다시 한 번 확인

탐색적 데이터 분석(EDA) — 주요 공정 변수 비교


원본 데이터(real_data.csv) 기준 · Pass/Fail 별 공정 변수 분포 비교




Injection Time by Pass / Fail



Cycle Time by Pass / Fail



Barrel Temperature 평균 (Pass / Fail)



불량(N) 그룹은 사출시간·사이클타임에서 이상치가 두드러지고, 배럴 온도는 전 구간에서 정상(Y) 대비 근소하게 높게 나타남 — 이러한 공정 변수들이 모델의 주요 판별 특징으로 활용됨

최적 모델 선정 — 성능 비교

6개 베이스라인 모델을 학습해 Accuracy·Precision·Recall·F1을 비교했다

2-1. 모델 성능 비교표

Model	Accuracy	Precision	Recall	F1
★ Gradient Boosting	0.991	0.455	0.357	0.400
Decision Tree	0.989	0.385	0.357	0.370
Random Forest	0.989	0.385	0.357	0.370
Logistic Regression	0.993	1.000	0.214	0.353
SVM	0.993	1.000	0.214	0.353
KNN	0.993	1.000	0.214	0.353





인사이트 Logistic Regression · SVM · KNN은 Precision 1.000으로 오탐은 없지만 Recall 0.214에 그쳐 불량을 다수 놓친다. 반면 트리 계열(Decision Tree · Random Forest · **Gradient Boosting**)은 Recall과 F1이 더 높아 불량 검출에 유리 — 그중 F1이 가장 높은 Gradient Boosting과 Random Forest를 유력 후보로 압축했다.

최적 모델 선정 — 심층 비교 및 결정

유력 후보 Random Forest · Gradient Boosting을 5-Fold 교차검증으로 재비교해 최종 모델을 확정했다

2-2. Random Forest vs Gradient Boosting (5-Fold Cross Validation)



최종 모델: Gradient Boosting

- Recall 0.521 · AUC 0.923 (5-Fold 평균, Random Forest 대비 Recall +0.127) → STEP 3 전처리·정밀 학습에서 세부 튜닝 진행

2

STEP 2

전처리 및 모델 학습

STEP2에서 압축한 후보를 대상으로 전처리 후 GridSearchCV 5-Fold로 정밀 학습한다

2-3. 공통 전처리 파이프라인



수치형 변수 → Scaling (표준화)



범주형 변수 → One-Hot Encoding



4가지 조건 병렬 학습

2-4. 모델 학습 조건 (GridSearchCV · 5-Fold)

조건 1



Random Forest

원본 데이터 + 클래스 가중치

GridSearchCV · 5-Fold

조건 2



Random Forest

SMOTE 데이터 증강

GridSearchCV · 5-Fold

조건 3



Gradient Boosting

원본 데이터 + 클래스 가중치

GridSearchCV · 5-Fold

조건 4



Gradient Boosting

SMOTE 데이터 증강

GridSearchCV · 5-Fold



목표 지표 Recall(불량 미탐 방지)을 무조건 최우선 기준으로 적용


3

STEP 3

최적 모델 선정 — 최종 확정

4가지 학습 조건을 비교해 Gradient Boosting을 최종 모델로 확정한다

3-1. 조건별 비교



선정 기준 Recall이 가장 높고, Precision 방어(오탐 억제)가 잘 된 **Gradient Boosting** 모델을 1등으로 픽업



최종 모델: Gradient Boosting → STEP 3에서 전처리 후 정밀 학습, STEP 4에서 Threshold(임계값) 튜닝으로 최종 실전 검증 진행

4

STEP 4

실전 평가 및 임계값 튜닝

봉인해 둔 Test Data(20%)로 최종 검증하고 현장 기준을 확정한다



4-1

Test Data 주입

봉인해뒀던 Test Data(20%)를 Gradient Boosting 모델에 투입



4-2

불량 확률 예측

데이터별 '불량일 확률(Probability)' 산출



4-3

임계값 시뮬레이션

Threshold 0.2 ~ 0.8 구간을 직접 조정하며 비교

Threshold 시뮬레이션 — 미탐 vs 오탐 트레이드오프

Threshold ↓ → 미탐(불량 놓침) 위험 ↑

Threshold ↑ → 오탐(정상 오판) 위험 ↑



비용 비교: 불량을 정상으로 놓치는 미탐 비용 vs 정상을 불량으로 오판하는 오탐 비용



최종 결론 상황에 맞는 최적의 Threshold 확정

증강 데이터 기반 모델 성능 검증



SMOTE로 증강한 데이터(add_data.csv)로 학습한 Random Forest · Gradient Boosting 모델의 저장 모델 성능

저장 모델 성능 비교

적용 모델	정확도	정밀도	재현율	F1 점수	ROC-AUC
Random Forest	0.997	0.998	0.996	0.997	1.000
Gradient Boosting	0.997	0.997	0.997	0.997	1.000


※ 재학습하지 않고, 저장된 모델로 현재 불러온 증강 데이터 csv 전체를 예측한 참고 성능입니다. (STEP 2의 5-Fold 교차검증 성능과는 별도 지표)



확인 사항 SMOTE로 양품:불량 = 5:5 비율로 균형을 맞춘 데이터에서는 두 모델 모두 재현율 0.996 이상으로 불량을 거의 놓치지 않는 것으로 나타나, 데이터 증강이 학습에 유효했음을 다시 한 번 확인했다.

예측 결과 대시보드 — 변수별 탐색 (1)

학습된 모델로 증강 데이터를 인터랙티브하게 탐색한 화면 · 상세 분석 변수: Average_Screw_RPM



타킷 분포(양품 8,000 · 불량 8,000)가 균형을 이루고, 평균 스크류 회전수(RPM)는 불량군에서 값이 특정 구간에 좁게 몰리는 경향을 보여 모델이 이 변수를 판별에 활용할 수 있음을 시사한다.

예측 결과 대시보드 — 변수별 탐색 (2)

상세 분석 변수: Max_Injection_Pressure · Barrel_Temperature_1




최대 사출압력·배럴 온도 1도 Max_Back_Pressure와 함께 볼 때 불량(1) 데이터가 양품(0)과 구분되는 군집을 형성하는 경향을 보여, 두 변수 모두 모델의 판별 근거로 함께 활용된 것으로 확인된다.

결과물 — 불량 예측 프로그램

SMOTE로 증강한 데이터로 학습한 Gradient Boosting · Random Forest 모델 기반



프로그램 개요 — Input → Process → Output



※ 실제 예측 결과 대시보드 화면은 앞 페이지 참고, 프로그램 시연은 별도로 진행합니다.



결과물 불량 예측 프로그램 — 현장 투입 전 사출성형 불량을 사전에 예측해 품질 비용 절감에 기여

불량 예측 프로그램 실제 동작 화면 데모



KAMP 데이터셋 · 현대자동차 아반떼 CN7 앞유리 사이드 몰딩 사출성형 공정 데이터

감사합니다

김재원 · 오선규 · 성재원